

- **Introducción a los Sistemas de Aprendizaje Automático**

El documento introduce el aprendizaje automático como una técnica clave en la era de la digitalización. Estas técnicas se utilizan en muchos sectores para mejorar la eficiencia y automatizar procesos. El objetivo del módulo es que los estudiantes aprendan a seleccionar y aplicar los algoritmos adecuados tanto en **aprendizaje supervisado** como **no supervisado** y optimicen los resultados de los modelos.

El módulo está basado en el uso de la biblioteca **Scikit-learn** para aprendizaje automático en **Python**, y **Keras** para el desarrollo de redes neuronales, en especial para redes profundas. Para evitar problemas de compatibilidad de versiones, se recomienda utilizar **Google Colab** como entorno de ejecución en la nube, facilitando la colaboración y la distribución de archivos sin necesidad de configuración local.

- **Inteligencia Artificial fuerte y débil**

El concepto de **Inteligencia Artificial (IA)** se divide en dos grandes ramas:

- **IA Fuerte:** Se refiere a sistemas que intentan replicar completamente el comportamiento y la capacidad de razonamiento humano. Esto incluye la capacidad de actuar en entornos con incertidumbre, como lo haría una mente humana. Este enfoque sugiere que las máquinas podrían llegar a ser autoconscientes y entender el mundo de manera autónoma. Esta idea surge de la "máquina de Turing universal", que teóricamente puede resolver cualquier problema computacional.
- **IA Débil:** Se enfoca en sistemas diseñados para realizar tareas específicas, sin emular completamente la inteligencia humana. Es la rama más utilizada hoy en día y ha permitido avances significativos como el **Machine Learning (ML)**, que busca resolver problemas específicos mediante el análisis de datos. Ejemplos notables son el ordenador **Deep Blue** de IBM, que derrotó al campeón mundial de ajedrez, y el sistema **Watson**, también de IBM, que ganó el concurso televisivo Jeopardy usando procesamiento de lenguaje natural y aprendizaje sin supervisión.

J. C. R. Licklider fue un pionero de la IA, pronosticando en la década de los años 60 del siglo pasado que la aparición de la IA fuerte no iba a ser inminente y requeriría un periodo interino de entre 10 y 500 años en el cual los humanos y los ordenadores existiría una relación simbiótica en el que las máquinas ayuden de forma efectiva el procesos de pensamiento. Argumentó que trabajarían con los humanos, existiendo como organismos diferentes, pero viviendo juntos en una asociación íntima que mejoraría ciertas capacidades del pensamiento humano. El reto no el de construir máquinas que simulen la mente humano sino entender el proceso de conocimiento humano y desarrollar máquinas que ayuden/realicen aquellos aspectos de la solución de problemas más difíciles o tediosos para el ser humano.

- **Problemas éticos, morales y sociales de la IA**

El uso de IA plantea cuestiones éticas, morales y sociales que deben ser consideradas en su desarrollo y aplicación. Estados Unidos, Rusia y China han adoptado la IA sin muchas restricciones, mientras que la Unión Europea impone regulaciones como la **protección de datos**. El documento plantea algunas situaciones hipotéticas para reflexionar sobre los riesgos potenciales:

- **Responsabilidad en accidentes de vehículos autónomos:** Si un coche autónomo provoca un accidente, ¿quién es el responsable: el propietario, el fabricante o el desarrollador del software?
- **Vigilancia masiva con reconocimiento facial:** Aunque estas tecnologías son útiles para la seguridad, su uso plantea preguntas sobre la privacidad y las libertades civiles.
- **Desigualdades en el mercado laboral:** La automatización puede destruir empleos más rápido de lo que se crean nuevos, lo que plantea el problema de cómo redistribuir la riqueza generada por los robots.

Este tipo de preguntas refleja la necesidad de discutir y establecer marcos legales y éticos claros para el uso de la IA.

• Construcción de Modelos de Aprendizaje Automático

Un **modelo** de aprendizaje automático es una representación matemática de una realidad (dominio de aplicación). Un modelo no intenta descubrir la verdad subyacente de un fenómeno, sino que busca reproducir observaciones pasadas para hacer predicciones.

- El modelo M contesta a las preguntas que el observador O hace sobre la realidad R
- Los datos que genera el modelo M sobre la realidad R reproducen las observaciones que se dispone del fenómeno R .

El proceso de modelado sigue estas etapas:

- **Entradas y salidas:** El modelo considera la realidad como una "caja negra", donde las entradas xxx generan salidas yyy . El modelo trata de predecir la salida $y^{\hat{}}$ basándose en las observaciones previas de xxx y yyy .
- **Parámetros e hiperparámetros:** Los parámetros ajustan el modelo a los datos de entrada, mientras que los hiperparámetros determinan la estructura del modelo (por ejemplo, el grado de un polinomio en un modelo de regresión).

El documento menciona que el **entrenamiento del modelo** consiste en encontrar los valores óptimos para los parámetros, de manera que las predicciones del modelo coincidan lo más posible con las observaciones reales.

- **Técnicas Principales para Desarrollar Modelos de Aprendizaje Automático**

El aprendizaje automático incluye una variedad de técnicas que permiten a las máquinas aprender a realizar tareas a partir de datos. Estas técnicas se dividen en dos tipos principales:

- **Aprendizaje inductivo:** A partir de la observación de datos concretos, se extraen reglas generales. Los algoritmos como los **árboles de decisión** y las **redes neuronales** pertenecen a este grupo. Estos modelos funcionan como "cajas negras", en las que no es necesario conocer los mecanismos causales.
- **Aprendizaje deductivo:** Se parte de reglas generales para obtener conclusiones específicas, por ejemplo, en **sistemas expertos**. Sin embargo, este curso se enfoca principalmente en el aprendizaje inductivo.

- **Tipología de las variables**

Una clasificación de las variables en función de su naturaleza es:

- **Variables cuantitativas:** Los datos toman valores numéricos. A su vez se distingue entre variables continuas que toman valores en un intervalo de números reales o variables discretas, que toman un número finito de valores numéricos. Ejemplos de variables continuas son la edad, ingresos, altura, etc y como variables discretas el número de hijos, o el número de días realizando un tratamiento.

- **Variables ordinales:** Los datos expresan relación de orden entre las observaciones. Por ejemplo podemos considerar un ranking en ciertos tratamientos como el mejor (1), el segundo mejor (2), el tercer mejor (3), etc. Otro ejemplo son las variables que ordenan las preferencias de ciertos usuarios.

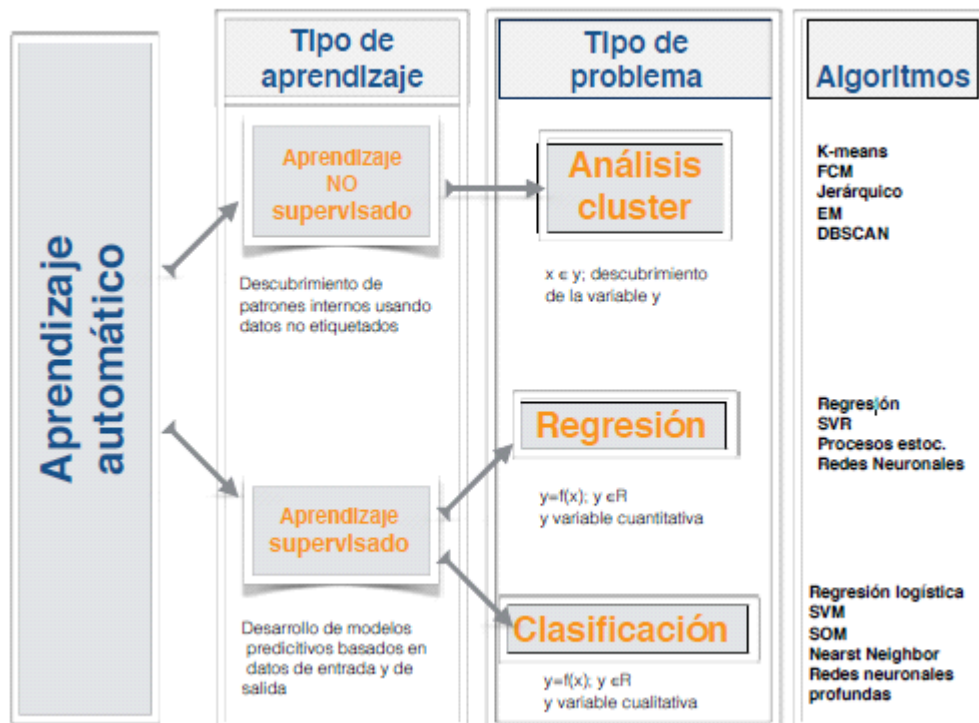
- **Variables cualitativas:** En este caso se expresa una cualidad de un objeto. Estas variables solo pueden tomar un conjunto de valores que no miden ninguna magnitud determinada. Por ejemplo, los sujetos de un experimento pueden ser hombre o mujer. Estos datos los podemos codificar dándole el valor 1 a los hombres y 2 a las mujeres. Esta variable no representa que el valor 2 es el doble del valor 1 (si fueran datos cuantitativos) o que unos son los segundos y los otros los primeros (datos ordinales) sino que son dos categorías diferentes.

- **Clasificación de Sistemas de Aprendizaje Automático**

El aprendizaje automático se clasifica según si el modelo dispone o no de etiquetas conocidas para las observaciones:

- **Aprendizaje supervisado:** Se basa en datos etiquetados, donde se conocen tanto las entradas xxx como las salidas yyy. Este tipo de aprendizaje incluye problemas de:
 - **Regresión:** Predicción de variables continuas.

- **Clasificación:** Predicción de categorías o etiquetas cualitativas.
- **Aprendizaje no supervisado:** No dispone de etiquetas en los datos. Los algoritmos intentan encontrar patrones internos en los datos sin saber de antemano los resultados correctos. Un ejemplo es el **clustering**, que agrupa datos similares en subconjuntos. Ejemplo de clustering, segmentación de mercados.



• Toma de Decisiones Basada en Modelos

La creación de modelos tiene como propósito ayudar en la **toma de decisiones**. Existen dos tipos principales de modelos:

- **Modelos de optimización (caja blanca):** Estos modelos explicitan los mecanismos causales y las restricciones. Se emplean en la toma de decisiones para maximizar o minimizar algún criterio (por ejemplo, maximizar ganancias o minimizar costos). Estos modelos son transparentes y se basan en la **optimización matemática**.
- **Modelos de aprendizaje automático (caja negra):** Estos modelos no explican los mecanismos que operan entre las variables, sino que se basan en correlaciones aprendidas de los datos para tomar decisiones. La fiabilidad de estos modelos depende de que las condiciones bajo las cuales se entrenaron sigan siendo válidas.

Además, se menciona una tercera alternativa, los **modelos híbridos (caja gris)**, que combinan optimización y aprendizaje automático para mejorar la toma de decisiones en situaciones complejas. Este enfoque permite mayor control sobre los mecanismos y facilita la

introducción de nuevas hipótesis o restricciones que no estaban presentes en los datos originales.

Ejercicio 1: Problema de optimización con máquinas

Se deben asignar dos tipos de productos (A y B) a dos máquinas (M1 y M2), maximizando el beneficio y respetando las restricciones horarias de las máquinas.

- **Variables de decisión:** x_A, x_B (unidades de productos A y B fabricadas).
- **Función objetivo:** $f(x_A, x_B) = 75x_A + 50x_B$
- **Restricciones:**
 - $x_A + 2x_B \leq 24$ (máquina M1).
 - $5x_A + x_B \leq 24$ (máquina M2).
 - $x_A, x_B \geq 0$ (enteros).

Ejercicio 2: Problema de la dieta

Formular un modelo de optimización para encontrar una dieta basada en arroz, pescado y verduras que cumpla con requerimientos mínimos de proteínas y calorías al menor costo.

- **Variables de decisión:** x_A, x_P, x_V (kilogramos de arroz, pescado y verduras).
- **Función objetivo:** minimizar el costo $f(x_A, x_P, x_V) = 1.5x_A + 7x_P + 2.5x_V$
- **Restricciones:**
 - $x_A + 3x_P + 2x_V \geq 3$ (proteínas).
 - $2000x_A + 3000x_P + 1000x_V \geq 4000$ (calorías).
 - $x_A, x_P, x_V \geq 0$.

Ejercicio 3: Maximización a partir de un problema de minimización

Formular un modelo de optimización para encontrar una recta $y = a + bx$ que mejor ajuste un conjunto de datos (x_i, y_i) minimizando la suma de los errores al cuadrado.

Ejercicio 4: Asignación de personas a tareas

Se plantea asignar N personas a J tareas de forma que se maximice la eficiencia total. Algunas consideraciones:

- Las tareas no son igualmente importantes (peso ω_j).

- Tiempo requerido para cada tarea (t_{jt}).
- Modelos de regresión $f_j(x)$ que estiman la eficacia de cada persona en una tarea.
- Cada persona puede dedicar 8 horas diarias.